

· CNN Tabanlı Beyin Tümörü Tespiti

· CNN-Based Brain Tumour Detection

· Kardelen Şeyma ERDEM

Mail: iletisimmkardelen@gmail.com

Özet

Beyin tümörlerinden kaynaklı insan ölümleri günümüzde artmaktadır. Beyin tümörü çok hızlı büyüyerek, normal boyutunun iki katına çıkabilir. Bu yüzden uzmanlar, Manyetik Rezonans (MR) görüntülerini inceleme sürecini dikkatli ve hızlı bir şekilde yapmalıdır [12]. Beyin tümörünün erken dönemde tespiti ile insanların yaşam kalitesi bozulmadan hızla tedaviye başlanabilmektedir. Aynı zamanda erken teşhis hastalığın iyileşme sürecinin daha hızlı olmasında da önemli rol oynamaktadır. Bu çalışmanın amacı beyin tümörü şüphesi taşıyan hastaların teşhis sürecini hızlandırma amacıyla süreci otomatize edebilmektir. Bu sayede şüphe taşıyan hastalar yüksek doğrulukla uzman incelemesine gerek kalmaksızın erken tanı ile hızlıca tedavi alabilirler. Çalışmada kullanılan CNN mimarisi günümüzde yalnız beyin tümörünün tespitinde değil çoğu kanser hücresinin tespitinde sıklıkla kullanılmaktadır. Burada CNN modelinin sıklıkla kullanılmasının en önemli nedeni maliyetin diğer mimari yapılara göre daha düşük olmasına rağmen elde edilen doğruluk oranının yüksek ve model karmaşıklığının yüksek olmasıdır. Yapılan çalışmada önerilen model 6 katman ve 14 aşamadan oluşmaktadır. Çalışmada açık kaynak görüntü kümesi kullanılmakla birlikte modeller ham veri ve artırım yapılmış veri üzerinde eğitilmiştir. Eğitim sonucunda model test edildiğinde %81 doğruluk oranında test görüntülerinin doğru tahmin ettiği gözlemlenmiştir.

Anahtar Kelimeler: Beyin tümörü tahminleme, CNN tabanlı tahminleme, MRG görüntülerinden tümör tespiti

Abstract

Human deaths from brain tumors are increasing nowadays. A brain tumor can grow very quickly, to double its normal size. Therefore, experts should carefully and quickly examine the Magnetic Resonance (MR) images [12]. With the early detection of a brain tumor, treatment can be started quickly without deteriorating the quality of life of people. At the same time, early diagnosis plays an important role in faster recovery of the disease. The aim of this study is to automate the process in order to speed up the diagnosis process of patients with suspected brain tumors. In this way, suspicious patients can get treatment quickly with early diagnosis without the need for expert examination with high accuracy. The CNN architecture used in the study is not only used in the detection of brain tumors, but also in the detection of most cancer cells. The most important reason why the CNN model is frequently used here is that although the cost is lower than other architectural structures, the obtained accuracy rate is high and the model complexity is high. The model proposed in the study consists of 6 layers and 14 stages. Although the open source image set is used in the study, the models are trained on raw data and augmented data. As a result of the training, when the model was tested, it was observed that the test images predicted correctly with an accuracy rate of 81%. The most important reason why the CNN model is frequently used here is that although the cost is lower than other architectural structures, the obtained accuracy rate is high and the model complexity is high. The model proposed in the study consists of 6 layers and 14 stages. Although the open source image set is used in the study, the models

are trained on raw data and augmented data. As a result of the training, when the model was tested, it was observed that the test images predicted correctly with an accuracy rate of 81%. The most important reason why the CNN model is frequently used here is that although the cost is lower than other architectural structures, the obtained accuracy rate is high and the model complexity is high. The model proposed in the study consists of 6 layers and 14 stages. Although the open source image set is used in the study, the models are trained on raw data and augmented data. As a result of the training, when the model was tested, it was observed that the test images predicted correctly with an accuracy rate of 81%.

Keywords:. Brain tumor prediction, CNN-based prediction, tumor detection from MRI images

1. GİRİŞ

Beyin tümörü, beynin kendi dokusunda yer alan hücrelerin farklılaşarak kontrolsüz bir şekilde çoğalmasıyla ya da vücudun farklı bir yerinde var olan kanser hücrelerinin kan dolaşımı yoluyla beyne ulaşarak bu bölgeye yayılmasıyla oluşan bir hastalıktır. Beyin, insan vücudunun hareketlerini kontrol eden duyum ve bilinç merkezidir. Kafatası içinde oluşabilecek tümörler büyüyerek beyne baskı yapabilir ve vücut sağlığına olumsuz etki edebilir [1]. Toplumda her 100 bin kişi arasında 3 ila 5 kişide bir görülen bu hastalığa, kadınlara oranla erkeklerde daha sık rastlanır. Hemen her yaş aralığında görülebilen beyin tümörü vakaları, 10 yaş altı çocuklarda ve 70 yaş üzerindeki kişilerde daha yaygındır.

Beyin tümörü etkenine bağlı olarak primer ve sekonder olarak tanımlanır. Primer beyin tümörü beynin kendi hücrelerinin kontrolsüzce çoğalmasıyla oluşur. Sekonder beyin tümörü ise vücudun farklı bölgelerinde (böbrek, akciğer, kolon gibi) kontrolsüz çoğalma sebebiyle oluşan tümörün kan dolaşımıyla (metastaz) beyne yerleşmesi ile oluşur. Sekonder beyin tümörlerinin tamamı kötü huylu olarak adlandırılmakla birlikte primer beyin tümörleri kendi arasında iyi huylu (benign) ve kötü huylu (malignant) olarak ayrılır. İyi huylu tümörler yavaş çoğalsada ileride kötü huylu olmaması için cerrahi işlem ile beyin dokusundan ayrılır. İyi huylu tümörlerin kötü huylu tümörlere göre iyileşme süresi daha hızlıdır ve tekrarlama olasılığı daha düşüktür.

Beyin tümörü nörolojik muayeneler ve radyolojik görüntüler ile tespit edilebilir. MRG beyin tümörünün tespitinde kullanılan radyolojik görüntüleme yöntemidir. Yan etkisi olmayan ve uzmanların çok kısa süre içerisinde makinalar aracılığıyla yüksek kalitede görüntüler elde ederek hastalıkların teşhisinde avantaj sağlayan görüntüleme yöntemine Manyetik Rezonans Görüntüleme (MRG) adı verilir [2]. Radyolojik görüntüleme yöntemleri aracılığıyla tümör tespiti çok zor olmasada tespit aşamasında uzman görüşü gereklidir.

2000’li yıllardan itibaren makine öğrenmesi algoritmaları donanımsal ve yazılımsal olarak daha geliştirilmiştir. Özellikle büyük ve karmaşık verilerle baş edebilme noktasında geleneksel makine öğrenmesi algoritmalarından daha etkin sonuçlar üretebilen yeni algoritmalar (teknikler) artık derin öğrenme adı altında incelenmektedir [3].

Derin öğrenme, günümüzde standart yapay sinir ağları mimarilerinin geliştirilmesi suretiyle oluşturulmuş tekniklerden oluşmaktadır. Söz konusu teknikler, farklı problem alanlarının ortaya çıkardığı ihtiyaçlar ve alternatif çözüm mekanizmaları neticesinde tasarlanmıştır [4]. Yapılan çalışmalarda derin öğrenme tekniklerinin görüntü işleme süreçlerinde de başarılı sonuçlar verdiği bilinmektedir. Bu noktada, yaygınlığı en çok bilinen tekniklerden biri de Evrişimsel Sinir Ağları (ESA / CNN: Convolutional Neural Networks) olarak bilinmektedir [5,6]. ESA modelleri özellikle entegre özellik çıkartım mekanizmaları ve birincil öncelikte görüntü tabanlı verilere dayalı tasarlanmış katman yapıları sayesinde görüntüye dayalı problemlerde etkin bir biçimde kullanılagelmiştir [7,8].

Günümüzde yapılan çalışmaların sonuçları incelendiğinde CNN modellerinin hastalık teşhisi, tümörün tam yerinin belirlenmesi ve ilaç dozu ayarlanması gibi problemlerde çok başarılı olduğu görülmektedir.

Çalışmanın ana motivasyonu, beyin tümörünün radyolojik bir görüntüleme yöntemi olan MRG görüntülerinden uzman analizine gerek kalmadan tespit edilebilmesidir. Bu sebeple yapılan çalışmada CNN tabanlı derin öğrenme mimarisi kuruldu ve model tümörlü ve tümörsüz beyin MRG görüntüleri ile eğitildi. Çalışma sonunda model test edildiğinde %86'lık başarı sağladı.

1.1. İlgili Çalışmalar

Literatür taraması yapıldığında son zamanlarda derin öğrenme yöntemleri ile kanser tespiti çalışmalarının ivme kazandığı görülmektedir.


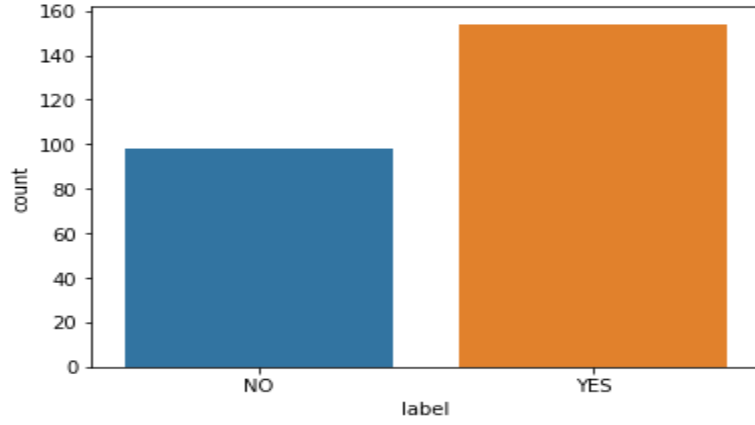
[9] Chaddtopathyay ve Maitra çalışmalarında beyin tümörü tespiti için CNN mimarisini kullanmışlardır. Aynı zamanda araştırmalarında beyin tümörü segmentasyon yöntemlerinin üzerinde durmuşlar ve üç segmentasyon yönteminden bahsetmişlerdir. İlk segmentasyon yöntemi olan Manuel Segmentasyon MRG görüntülerinin tamamının uzman gözlemine dayanması ve tümörlü bölgenin el ile belirlenerek kırılmasını gerektirmektedir. İkinci yöntem olan Yarı Otomatik Segmentasyon yöntemi ise tek bir beyin MRG'nın kendi içinde eğitilmesi ve uzman görüşünün kısmi müdahalesi ile gerçekleşir. Son yöntem olan Tam Otomatik Segmentasyon yöntemi çalışmada önerilen yöntem olup Evrişimsel Sinir Ağı (CNN) mimarisi kullanılarak segmentasyon işleminin insan gücü olmadan yapılmasına dayanmaktadır. Söz konusu çalışmada 19 farklı kurumdan toplanan gerçek klinik vakalarından oluşan Brats veri seti kullanılmıştır. Önerilen CNN model 14 aşamalı ve katmandan oluşmaktadır. Chaddtopathyay ve Maitra yaptıkları çalışmanın final modelinde aktivasyon fonksiyonu olarak 'Softmax', optimizasyon parametresi olarak ise 'RMSProp'u kullanmışlardır. Son olarak final modellerinin doğruluğunun %97.74 olduğunu bildirmişlerdir.

[10] Seetha ve Raja'nın çalışmalarında önerdikleri yöntem Chaddtopathyay ve Maitra'nın çalışmalarına benzer şekilde CNN tabanlı derin sinir ağı mimarisidir. Bu çalışmanın diğer çalışmadan farkı transfer learning yönteminin kullanılmasıdır. Seetha ve Raja daha önce ImageNet veri seti ile eğitilmiş modeli kullanarak yalnız son katmanı yeniden eğitmişlerdir. Model eğitiminde iki farklı veri seti kullanmış (Radiopedia ve Brats(2015)) nihai modellerinde %99.7 doğruluk skoruna ulaşmışlardır.

[11] Yılmaz ise yaptığı çalışmada CNN mimarisinden farklı olarak 5 kanallı Faster R-CNN mimarisi kullanmış ve özellik seçiminde ise kısmi korelasyon elemesini önermiştir. Modelinin doğruluğunu 3 farklı veri seti üzerinde test etmiş ve literatür çalışmalarıyla doğru karşılaştırma yapmak için VGG-16, DenseNet-201, ResNet-50 ve SRN mimarilerinde aynı veri setleri ile test etmiştir. Yaptığı çalışmalar sonucunda tüm veri setlerinde model doğrulukları karşılaştırıldığında en yüksek skorun %98.31 ile önerdiği model olduğu belirlenmiştir.

2. MATERYAL VE METODLAR

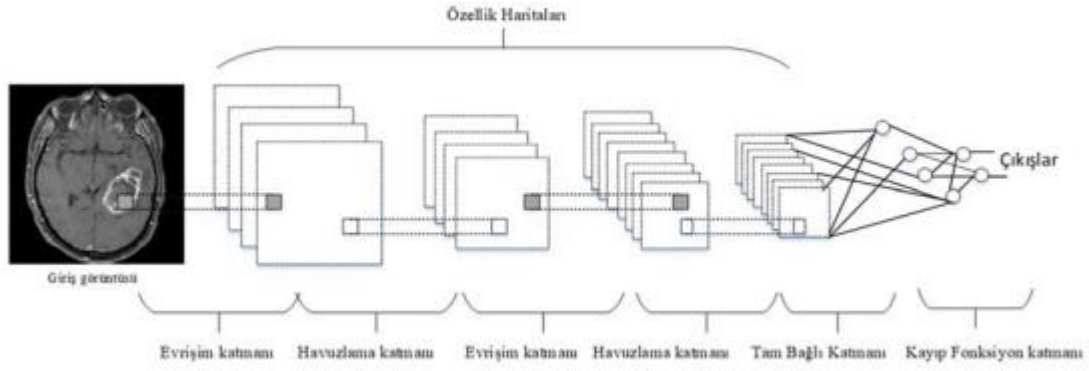
Yapılan çalışmada Evrişimsel Sinir Ağı (CNN) *mimarisi kullanılarak beyin tümörü tespiti çalışması yapılmıştır. Model eğitim, test ve doğrulamasında kullanılan veri seti ise açık kaynak olan Kaggle platformundan elde edilmiştir. Veri setinde bulunan tümörlü görüntüler (154) 'Yes', tümörsüz görüntüler (98) 'No' ile etiketlenmiştir. Veri setinin dağılımı aşağıdaki şekilde gösterilmiştir.




Veri setinden örnek görüntüler.

2.1. CNN Mimarisi

CNN, yapay sinir ağlarının ileriye dönük işlem yapan ve sinir ağlarından farklı olarak özellik çıkarıcı bir katmanın bulunduğu derin öğrenme yaklaşımıdır [12]. CNN’de temel olarak iki katman kullanılır. Bu katmanlar evrişim ve havuzlama katmanı olarak adlandırılır. Evrişim katmanında belirlenen parametreler ile görüntünün özellik çıkarımı yapılır, havuzlama katmanında ise en az bilgi kaybı olacak şekilde görüntüden elde edilen özellikler indirgenir. Bu işlem ile birlikte yüksek maliyeti azaltmak ve daha doğru sonuçlar elde edilmesi amaçlanır. Uygulanan bu evrişim ve havuzlama katmanı ile görüntü pikselleri ağırlıklandırılarak diğer katmana gönderilir ve bu katmanda yeniden bir evrişim adımı gerçekleşir. Son olarak tam bağlantı katmanı oluşturulur ve model çıktısının doğruluğunu ölçmek için bir kayıp fonksiyonu belirlenir. Kurulan model performansı kayıp fonksiyon çıktılarına göre düzenlenir ve nihai modele erişilir.



CNN Mimarisi



Havuzlama Katmanı

2.2 Veri Setinin Düzenlenmesi

2.2.1 Train – Test – Validation Split

Kaggle'dan toplamda 253 görüntü elde edilmiştir. Veri seti Yes ve No etiketleri dikkate alınarak 0.7'si model eğitiminde kullanılmak üzere ayrılmıştır. Veri setinin 0.3'ü ise benzer şekilde 0.5'li test, 0.5'i ise doğrulama (validation) için kullanılmak üzere bölünmüştür. Train, test ve doğrulama setleri aşağıdaki gibidir.

```
train labels:
YES    108
NO     68
Name: label, dtype: int64

validataion labels:
YES    23
NO     15
Name: label, dtype: int64

test labels:
YES    23
NO     15
Name: label, dtype: int64
```

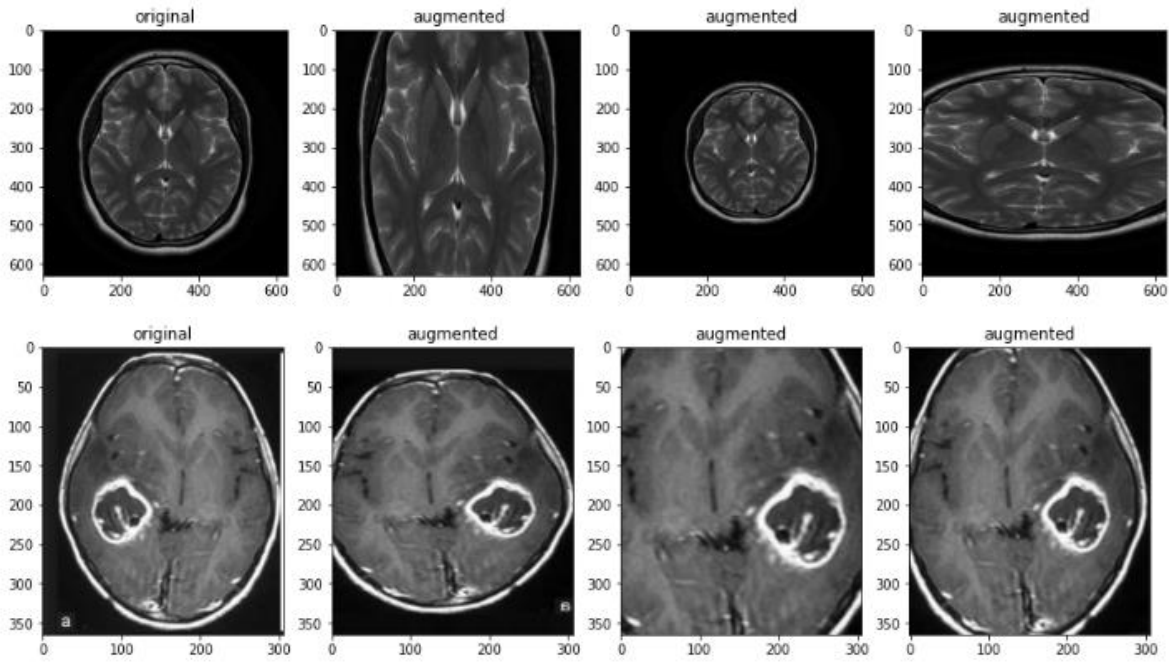
Train-Test-Validation Split

2.2.2 Veri Setinin Normalleştirilmesi

Veri setinde her bir görüntünün piksel sayısı farklı olduğu için eğitim, test ve doğrulama aşamalarından önce görüntüleri belirli bir dönüşüm işlemine tabii tutmamız gerekir. Proje kapsamında bu amaçla keras kütüphanesinin elemanı olan ImageDataGenerator kullanıldı. Rescale komutu ile görüntüler 0-1 aralığında olacak şekilde yeniden ölçeklendirildi (normalleştirildi). Bu işlem sırasıyla train, test ve doğrulama setlerine uygulandı.

2.2.3 Veri Artırımı

Temel CNN mimarisi kurulduktan sonra model başarısını ölçmek amacıyla iki senaryo üzerinde duruldu. İlk senaryoda kurulan CNN modeli yalnızca normalleştirilmiş ham veri seti ile eğitildi. İkinci senaryoda ise veriler normalleştirildikten sonra veri artırımı uygulandı. Aşağıdaki görselde tümörlü ve tümörsüz görüntülerin orijinal ve veri artırımı ile üretilmiş görüntülerini inceleyebilirsiniz.





3. DENEYSEL SONUÇLAR VE BULGULAR


Çalışmada önerilen modelde 6 katmanlı CNN mimarisi kullanılarak beyin tümörü tespit edilmiştir. Kurulan mimari ham veri seti ve artırılmış veri setine uygulanmıştır. Ara katmanlarda aktivasyon fonksiyonu olarak Relu ve Tanh kullanılmakla birlikte son katmanda ikili sınıf çıktısı almak için sigmoid aktivasyon fonksiyonu kullanılmıştır.

Model compile aşamasında ise optimizasyon parametresi 'Adam', kayıp fonksiyonu ise 'Binary Crossentropy' olarak belirlenmiştir.

- **Ham veri seti için model bulguları**




Ham veri seti için kurulan model incelendiğinde modelin eğitim ve doğrulama setindeki başarılarının birlikte arttığı görülmektedir. Eğitim setinin doğruluk metriğinin son öğrenme aşamasında yaklaşık %89'a, doğrulama setinin ise yaklaşık %72'ye ulaştığı görülmektedir. Model eğitim ve doğrulama kayıplarına bakıldığında ise model başarı grafiğini destekler şekilde öğrenme arttıkça kayıp oranının azaldığı söylenir.




Ham veri ile eğitilmiş modelden test görüntüleri tahmin ettirildiğinde yukarıdaki karmaşıklık matrisi elde edilmiştir. Karmaşıklık matrisinde satırlar görüntünün gerçek etiketini temsil ederken sütunlar ise modelden tahmin edilen görüntü etiketlerini temsil etmektedir. Buna göre kurulan model gerçekte tümör bulunmayan 15 görüntüden 12'sini doğru tahmin etmiş, 3 görüntüyü ise beyin tümörü olmadığı halde tümör var olarak tahmin etmiştir. Benzer şekilde gerçekte beyin tümörü bulunan 23 görüntüden 18'i doğru tahmin edilmiş, 5 görüntüde beyin tümörü olmasına rağmen tümör yok olarak tahmin edilmiştir.

- **Artırılmış veri seti için model bulguları**




Veri artırımı yapılmış veri seti ile CNN mimarisi eğitildiğinde ise eğitim seti doğruluk metriğinin yaklaşık %82, doğrulama seti doğruluk metriğinin ise yaklaşık %71 olduğu gözlemlenmektedir. İlk grafik eğitim ve doğrulama setleri için kayıp değerlerini ifade ederken ikinci grafik bu setlerin doğruluk oranlarını vermektedir.

- Tahmin eşik değeri>0.5



- Tahmin eşik değeri> 0.3



Veri artırımı ile kurulan modelden test setini tahmin ettirdiğimizde eşik değerin değiştirilmesinin test seti doğruluğunu artırdığı gözlenmiştir. Tahmin çıktısında olasılık eşik değerini 0.5'ten büyük olarak belirlediğimizde görüntülerin yaklaşık %76'sı doğru tahmin edilirken, bu değeri 0.3'ten büyük olarak belirlediğimizde görüntülerin yaklaşık %81'i doğru tahmin edilmiştir.

Modeller	Doğruluk
Ham Veri Seti	%78.9
Veri Artırımı Yapılmış Model (Eşik değeri >0.5)	%76.3
Veri Artırımı Yapılmış Model (Eşik değeri >0.3)	%81.6

4. SONUÇ VE ÖNERİLER

Sonuç olarak Kaggle'dan elde edilen 253 görüntü içeren veri seti kullanılarak iki farklı senaryoda üç farklı tahmin çıktısı elde edilmiştir. Bu modeller eğitim ve doğruluk setlerinin doğruluk metriği açısından incelendiğinde ham veri seti en yüksek skoru vermişken eşik değeri değiştirildikten sonra veri artırımı yapılarak kurulan model skorunun yükseldiği gözlemlenmiştir. Bu sebeple nihai model olarak veri artırımı uygulanan 6 katmanlı CNN mimarisi ile kurulan model seçilmiştir.

Bu çalışmada kullanılan veri seti farklı klinik kaynaklardan elde edilen veri setleri kullanılarak model başarısı artırılabilir düzeydedir. Buna ek olarak yapılacak diğer çalışmalarda farklı istatistiksel özellik seçim yöntemleri kullanılarak söz konusu mimari yapı geliştirilebilir. Yapılan çalışma literatürdeki diğer modeller ile karşılaştırıldığında elde edilen model başarısının diğer çalışmalara göre daha düşük kaldığı düşünülebilir. Ancak incelenen literatür çalışmalarda transfer learning, korelasyona yönelik özellik çıkarımı, Faster R-CNN gibi farklı mimariler ve farklı özellikleri ile kurulduğu unutulmamalıdır. Bunlara ek olarak derin öğrenme yöntemlerinde görüntü sayısının artırılmasının model başarısını doğrudan etkilediği bilinmektedir.

Kaynakça

1. Arı, Hanbay Tumor detection in MR images of regional convolutional neural networks, 2019
2. Shang,H., Zhao, W., Zhang, W., Preoperative Assessment Using Multimodal Functional Magnetic Resonance Imaging Techniques in Patients with Brain Gliomas, Turkish Neurosurgery, 22 (5),558-565,2012.
3. Goodfellow, I., Bengio, Y., Courville, A., Bengio, Y., “Deep Learning”, Vol. 1, MIT Press, Cambridge: USA, (2016).
4. Orman, Köse, Yiğit, Açıklanabilir EvriGimsel Sinir Ağları ile Beyin Tümörü Tespiti El-Cezerî Fen ve Mühendislik Dergisi Cilt: 8, No: 3, 2021 (1323-1337)
5. Albawi, S., Mohammed, T. A., Al-Zawi, S., “Understanding of a convolutional neural network”, International Conference on Engineering and Technology (ICET), Antalya: Turkey, 1-6, (2017).
6. Lee, H., Song, J., Introduction to convolutional neural network using Keras; an understanding from a statistician, Communications for Statistical Applications and Methods (CSAM), 2019, 26 (6): 591-610.

- 7. Lu, L., Zheng, Y., Carneiro, G., Yang, L., Deep learning and convolutional neural networks for medical image computing, Advances in Computer Vision and Pattern Recognition (ACVPR), 2017, 10: 978-983.**
- 8. Ren, Y., Cheng, X., “Review of convolutional neural network optimization and training in image processing”, International Symposium on Precision Engineering Measurements and Instrumentation, Chongqing: China, 1105331, (2019).**
- 9. ArkapravoChattopadhyay, MausumiMaitra MRI-based brain tumour image detection using CNN based deep learning method, Neuroscience Informatics Volume 2, Issue 4, December 2022, 100060**
- 10. J. Seetha and S. Selvakumar Raja, Brain Tumor Classification Using Convolutional Neural Networks, Biomedical and Pharmacology Journal**
- 11. Atınç Yılmaz Brain tumor detection from MRI images with using proposed deep learning model: the partial correlation-based channel selection, Turkish Journal of Electrical Engineering & Computer Sciences, Turk J Elec Eng & Comp Sci (2021) 29: 2615 – 2633**
- 12. Ari, B., Sengur, A., Ari, A., Hanbay D., Apricot Plant Classification Based On Leaf Recognition by Using Convolutional Neural Networks, International Conference on Natural Science and Engineering (ICNASE’16), Kilis, Türkiye, 19-20 Mart, 2016.**